

Componentes Principales

Oscar Centeno Mora

Introducción

- El análisis por componente principales hace parte de un grupo de análisis descriptivos multidimensionales llamados métodos factoriales.
- Creados en los años 30 y desarrollados en los años 60 donde se mejore los aspectos geométricos y las representaciones gráficas.
- Son métodos descriptivos, no se apoyan en modelos probabilísticos sino más bien de un modelo geométrico.
- A partir de una matriz rectangular de datos con p variables cuantitativas y n unidades, el análisis por componentes principales propone diversas representación geométricas de estos dos.
- Lo que se busca es ver si existe una estructura, no conocida a priori, para el conjunto de casos y variables.

Introducción


- Lo que se busca es ver si se pueden buscar grupos de unidades con diferencias o similitudes.
- Para las variables buscamos ver cuáles están muy correlacionadas entre ellas, y, de forma contraria, cuales no están correlacionadas con las otras.
- En la visualización de los individuos o unidades, se utiliza el concepto de las distancias entre los individuos.
- En la visualización de las variables, estas se llevan a cabo en función de sus correlaciones

Introducción

- En el análisis por PCA se deben de tomar en cuenta siempre las medidas de calidad de las representaciones: criterio global y criterios individuales.
- A veces se recomienda nombrar a los nuevos ejes, y de ahí explicar la posición de los individuos.
- Después de la explicación del método, no se debe olvidar de donde provienen los datos utilizados, lo que representan y el significado para el contexto en causa.
- Como todo método descriptivo, llevar a cabo un PCA no es un fin en sí. El PCA sirve para conocer mejor los datos, detectar valores sospechosos, y ayuda a formular hipótesis que se deben estudiar mediante modelos inferenciales.

El PCA: los datos


- Los datos corresponden a variables cuantitativas observadas para n individuos.



INDIVIDUO = elemento del espacio R^p
VARIABLE = elemento del espacio R^n

El PCA: los datos


- Se trata de visualizar una nube de individuos. Cada individuo denominado e_i , se puede asociar un punto en el eje R^p , o espacio de los individuos.
- Cada variable de la matriz X es asociada a un eje de R^p .



Impossible visualizar a partir de $p>3$.


El PCA: objetivo

- Se busca representar a los n individuos o casos, para un sub espacio vectorial F_k de R_p de dimensión k (k pequeño como 2, 3,...; por ejemplo un plano).
- En otras palabras, se busca definir k nuevas variables que son combinaciones lineares de las p variables iniciales, que en su conjunto tratarán de optimizar la perdida de información dado el proceso de reducción de variables.




- Las nuevas variables se denominarán como ***componentes principales***, los ejes serán llamados ***ejes principales***, y las formas lineares asociadas se llamarán ***factores principales***.

El PCA: nuevo espacio vectorial



Espacio vectorial inicial




Nuevo espacio vectorial con los
ejes principales

Los individuos

El PCA: la menor perdida posible de información

- En la definición de los ejes principales, F_k deberá ser ajustado lo mejor posible a la nube de los individuos: la suma de cuadrados de las distancias de los individuos a los F_k tiene que ser mínima.
- F_k es el sub espacio tal que la nube proyectada deba tener una inercia (dispersión) máxima.
- Los dos puntos anteriores se fundamentan sobre la noción de distancia y proyección ortogonal.

El PCA: la menor perdida posible de información



La distancia entre f_i y f_j es inferior o igual a la distancia entre e_i y e_j .

El PCA: la elección de distancia entre los individuos

- En el espacio R^p de p dimensiones, se generaliza la siguiente noción: la distancia euclíadiana entre dos individuos se expresa como:


$$e_i = (x_i^1 \ x_i^2 \ \dots \ x_i^p)$$

$$e_j = (x_j^1 \ x_j^2 \ \dots \ x_j^p)$$

$$d^2(e_i, e_j) = (x_i^1 - x_j^1)^2 + (x_i^2 - x_j^2)^2 + \dots + (x_i^p - x_j^p)^2$$

- Por lo tanto

$$d^2(e_i, e_j) = \sum_{k=1}^p (x_i^k - x_j^k)^2$$



$$d^2(A, B) = (x_B - x_A)^2 + (y_B - y_A)^2$$

El PCA: la elección de distancia entre los individuos

- Cuando se tienen variables con diferentes unidades de medida, el problema se revuelve transformando los datos mediante el proceso de la estandarización.

- La observación X_i^k se remplaza por:

$$\frac{X_i^k - \bar{X}^k}{s_k}$$

- Nótese que al realizar la estandarización, suponemos la normalidad de los datos.

El PCA: la inercia total

- La inercia es la suma ponderada de las distancias cuadradas de los individuos para el centro de gravedad \underline{g} .
- La inercia mide la dispersión total de la nube de puntos.
- La inercia se expresa como:

$$I_{\underline{g}} = \sum_{i=1}^n \frac{1}{n} d^2(e_i, \underline{g})$$

O de forma general

$$I_{\underline{g}} = \sum_{i=1}^n p_i d^2(e_i, \underline{g})$$

$$\sum_{i=1}^n p_i = 1$$

El PCA: la inercia total

- La inercia es por lo tanto igual a la suma de las variancias de las variables estudiadas.
- Si denominamos V la matriz de variancias y covariancias:

$$V = \begin{pmatrix} s_1^2 & s_{12} & \dots & s_{1p} \\ \vdots & s_2^2 & & \vdots \\ \vdots & & & \vdots \\ s_{p1} & & & s_p^2 \end{pmatrix}$$

$$I_g = \sum_{i=1}^p s_i^2$$


$$I_g = \text{Tr}(V)$$

- En el caso donde las variables son estandarizadas, la variancia de cada variable es de 1.
- Por lo tanto, en el caso anterior, la inercia es igual a p (total de variables).

El PCA: sobre la equivalencia en la perdida de información

- Sea F es un sub espacio de \mathbb{R}^P
- f_i la proyección ortogonal de e_i sobre F se representa como

$$\|e_i - \underline{g}\|^2 = \|e_i - \underline{f}_i\|^2 + \|\underline{f}_i - \underline{g}\|^2 \quad \forall i = 1 \dots n$$



Proyección ortogonal de la nube
sobre el sub espacio

El PCA: sobre la equivalencia en la perdida de información

- Se busca para F que sea mínimo:

$$\sum_{i=1}^n p_i \|\underline{e}_i - \underline{f}_i\|^2$$

- Lo que equivaldría que, según el teorema de Pitágoras a maximizar la siguiente expresión:

$$\sum_{i=1}^n p_i \|\underline{f}_i - \underline{g}\|^2$$

- De lo anterior se obtiene:

$$\|\underline{e}_i - \underline{g}\|^2 = \|\underline{e}_i - \underline{f}_i\|^2 + \|\underline{f}_i - \underline{g}\|^2 \quad \forall i = 1 \dots n$$

- Y por lo tanto:

$$\underbrace{\sum_{i=1}^n p_i \|\underline{e}_i - \underline{g}\|^2}_{\text{Inercia total}} - \underbrace{\sum_{i=1}^n p_i \|\underline{e}_i - \underline{f}_i\|^2}_{\text{Minimizar distancia entre individuos y la proyección}} = \underbrace{\sum_{i=1}^n p_i \|\underline{f}_i - \underline{g}\|^2}_{\text{Maximizar inercia de la nube proyectada}}$$

Inercia total

Minimizar distancia entre individuos y la proyección

Maximizar inercia de la nube proyectada

El PCA: solución al problema originado

- La búsqueda de los ejes con el máximo de inercia equivale a la construcción de nuevas variables con máxima variancia (las variables están asociadas a los nuevos ejes mediante combinaciones lineales).
- En otros términos, realizamos un cambio del sistema de referencia en el espacio R^p de manera de colozarse en un nuevo sistema de representación donde el primer eje aporta la mayor cantidad posible de inercia total a la nube, el segundo eje la mayor cantidad de inercia no tomada en cuenta en el primer eje, y así consecutivamente.
- Esta reorganización se apoya sobre la diagonalización de la matriz de variancia y covariancia.

El PCA: solución al problema originado

- Sobre los ejes principales, denominamos ejes principales de inercia a los ejes de direcciónan los vectores propios de V normados en 1.
- En total hay p .
- El primer eje está asociado a la mayor cantidad de valores propios. Lo notamos como u^1 .
- El segundo eje está asociado a la mayor cantidad de valores propios. Lo notamos como u^2 .

El PCA: solución al problema originado

- A cada eje está asociado una variable llamada componente principal.
- El componente c^1 es el vector que contiene las coordenadas de las proyecciones de los individuos sobre el eje 1.
- El componente c^2 es el vector que contiene las coordenadas de proyecciones de los individuos sobre el eje 2.
- Para obtener dichas coordenadas, cada componente principal es una combinación lineal de las variables iniciales.

$$\underline{c}^1 = u_1^1 \underline{x}^1 + u_2^1 \underline{x}^2 + \dots u_p^1 \underline{x}^p$$

El PCA: propiedad de los componentes principales

1. La variancia de un componente principal es igual a la inercia contribuida al eje principal que le es asociado.

1^{ère} composante \mathbf{c}^1 variance : λ_1

2^{ème} composante \mathbf{c}^2 variance : λ_2

3^{ème} composante \mathbf{c}^3 variance : λ_3

2. Los componentes principales no están correlacionados entre ellos. En efecto, los ejes asociados son ortogonales


El PCA: representación de los individuos

- Los j componentes principales brindan la información para ubicar a los n individuos sobre los j ejes principales.
- El vector que permite ubicar a los individuos se presenta como:

$$\underline{c}^j = \begin{pmatrix} c_1^j \\ c_2^j \\ \vdots \\ \vdots \\ c_n^j \end{pmatrix}$$

- En la práctica, si se desearía una representación plana de los individuos, lo mejor sería utilizar los dos primeros componentes principales.

El PCA: representación de los individuos



- Se debe de tener cuidado con la calidad de la representación de cada individuo.


El PCA: representación de los individuos

- El objetivo es ver patrones a aglomeraciones de los casos.
- Es importante, de ser posible, nombrar al eje principal para mejorar la calidad del análisis.
- A veces, los casos muy aparte del resto de los individuos, son complicados de describir o comprender. Se les suele dar la denominación de valor atípico.

Las variables

El PCA: la representación de las variables

- Las *proximidades* entre los componentes principales y las variables iniciales son medidas por la covariancia, y sobre todo con las correlaciones.
- El coeficiente de correlación lineal entre c_j y x_i se denota como $r(c^j, x^i)$



El PCA: interpretación de la proximidad entre variables

- Se utiliza un producto escalar entre variables que permiten asociar a los parámetros conocidos: desviación estándar, coeficiente de correlación lineal en las representaciones geométricas (se parte de que las variables están centradas).

$$\left\langle \underline{x}^i, \underline{x}^j \right\rangle = \frac{1}{n} \sum_{k=1}^n x_k^i x_k^j$$

- Las ecuaciones restantes son:

$$\left\langle \underline{x}^i, \underline{x}^j \right\rangle = \text{Cov} (\underline{x}^i, \underline{x}^j)$$

$$\left\| \underline{x}^i \right\|^2 = s_i^2$$

$$\left\| \underline{x}^i \right\|^2 = \left\langle \underline{x}^i, \underline{x}^i \right\rangle = \frac{1}{n} \sum_{k=1}^n (x_k^i)^2$$


$$\left\| \underline{x}^i \right\| = s_i$$

El PCA: coeficiente de correlación lineal

- Para asociar a las variables en el circulo de relación, el coseno del ángulo formado por las variables X_i y X_j es el coeficiente de correlación lineal de las dos variables.

$$\cos(\widehat{\underline{X}^i, \underline{X}^j}) = \frac{\langle \underline{x}^i, \underline{x}^j \rangle}{\|\underline{x}^i\| \|\underline{x}^j\|} = \frac{\text{Cov}(\underline{X}^i, \underline{X}^j)}{s_i s_j} = r(\underline{X}^i, \underline{X}^j)$$

- Una interpretación según el círculo es la siguiente:



X^1 y X^2 poseen una correlación cercana a 1.

X^1 y X^3 poseen una correlación cercana a 0.

Validación de los resultados

El PCA: validación de la representación gráfica

- Para conocer la validez de los resultados globales, se pueden utilizar criterios de la parte explicada por la inercia para el eje i .

$$\frac{\lambda_i}{\lambda_1 + \lambda_2 + \dots + \lambda_p}$$


- Para el caso de los dos primeros componentes, utilizaríamos el siguiente criterio.

$$\frac{\lambda_1 + \lambda_2}{\sum_{i=1}^p \lambda_i}$$

- Este criterio, muy a menudo expresado en porcentaje, mide el grado de reconstitución de los cuadrados según la distancia.
- Entre mayor correlación entre las variables, la reducción de variables será más contundente.

El PCA: cantidad de ejes


- Para determinar la cantidad de ejes, se puede utilizar el porcentaje de inercia requerido (a priori), o dividir la inercia total según la cantidad de variables iniciales.
- Otro método es dibujar un histograma con todas las contribuciones de todas las inercias, y ver donde es que se da un punto de corte. Este método tiene por representación el gráfico de sedimentación.
- En este se conservan los ejes o el número de componentes situados antes del corte.



En este caso
elegiríamos 3
componentes.

El PCA: criterios individuales

- Se utiliza los cosenos cuadrados:



$$\cos^2 \theta = \cos^2 \theta_1 + \cos^2 \theta_2$$

El PCA: criterios individuales

- Para *cada* individuo, la calidad de la representación se define por el cuadrado del coseno del ángulo entre el eje de proyección y el vector e_i . Entre más cerca es cercana a 1, mejor es la calidad de la representación.
- En general, las calidades en la representación están dadas eje a eje. Para tener la calidad de la representación en un plano, se suma los criterios correspondientes a los ejes estudiados.
- Este criterio no tiene sentido para los casos cercanos del origen.
- Si se detectan individuos con cosenos cuadrados débiles, se debe tener cuenta de su distancia al origen antes de pensar sobre una mala representación.

El PCA: criterios individuales

- Es útil también calcular para cada eje la contribución brindada para los diversos individuos al eje.
- Consideremos el k -ésimo componente principal C^k , sea C_i^k el valor del componente para el individuo i . Este en término de **inercia** sería:

$$\sum_{i=1}^n \frac{1}{n} (c_i^k)^2 = \lambda_k$$

- La **contribución** del individuo i al componente $nº k$ se definiría por la ecuación:


$$\frac{\frac{1}{n} (c_i^k)^2}{\lambda_k}$$

El PCA: criterios individuales

- No es aconsejable que un individuo tenga una contribución excesiva, dado que provoca la inestabilidad.
- En dicho caso se prefiere eliminar al o los casos que poseen contribución importantes.
- Este caso se puede presentar en las encuestas por muestreo.

El PCA: representación de las variables

- El círculo de las correlaciones es la proyección de la nube de las variables sobre el plano de los componentes principales.
- Las variables que están bien representadas son aquellas que están cercanas al círculo. Caso contrario, aquellas cerca del origen están mal representadas.



Correlación = coseno

Ejemplos ilustrativos

- Los ejemplos se encuentran en el laboratorio y en los siguientes enlaces:
- <http://www.sthda.com/english/wiki/principal-component-analysis-in-r-prcomp-vs-princomp-r-software-and-data-mining>
- http://www.sthda.com/english/wiki/ade4-and-factoextra-principal-component-analysis-r-software-and-data-mining#at_pco=smlwn-1.0&at_si=58d852c3ce898442&at_ab=per-2&at_pos=0&at_tot=1
- http://www.sthda.com/english/wiki/principal-component-analysis-how-to-reveal-the-most-important-variables-in-your-data-r-software-and-data-mining#at_pco=smlwn-1.0&at_si=58d2e52d6d391656&at_ab=per-2&at_pos=0&at_tot=1
- <http://www.sthda.com/english/wiki/factominer-and-factoextra-principal-component-analysis-visualization-r-software-and-data-mining>

THE END