

NP1602 – Introducción al Análisis Multivariado

# Proyecto Final: Árboles de Decisiones

Presentado por:

**Yanina Araya P.**

**Renato Guadamuz F.**

# Contenidos

- Caso en estudio
- Objetivo y Justificación
- Análisis descriptivo
- Resultados
  - Classification and Regression Tree (CART)
  - Inferencia condicional
- Conclusiones

# Caso en estudio

- Ingreso neto por trabajo
  - ENAHO 2016
  - Personas con trabajo remunerado
  - Mayores de 15 años
- $n = 794$  personas
- Características de las personas:
  - Educación
  - Sociales
  - Demográficas

# Objetivo

- Conocer los ingresos y las características de la población que los perciben con el fin de dar el apoyo preciso a los diferentes sectores de la población de acuerdo con sus necesidades.

# Justificación

- Analizar la población por sectores para estudiar sus ingresos y por lo tanto intuir sus gastos.
- Estudiar la desigualdad de género a nivel de ingreso en Costa Rica.
- Concientizar a la población y el Estado de las ventajas de una población con educación de calidad.

# Variables

- Continuas:
  - Edad
  - Años de escolaridad
  - **Ingreso neto por trabajo**
- Categóricas:
  - Región
  - Zona
  - Sexo
  - Migrante
  - Nivel de educación
  - Estado Civil

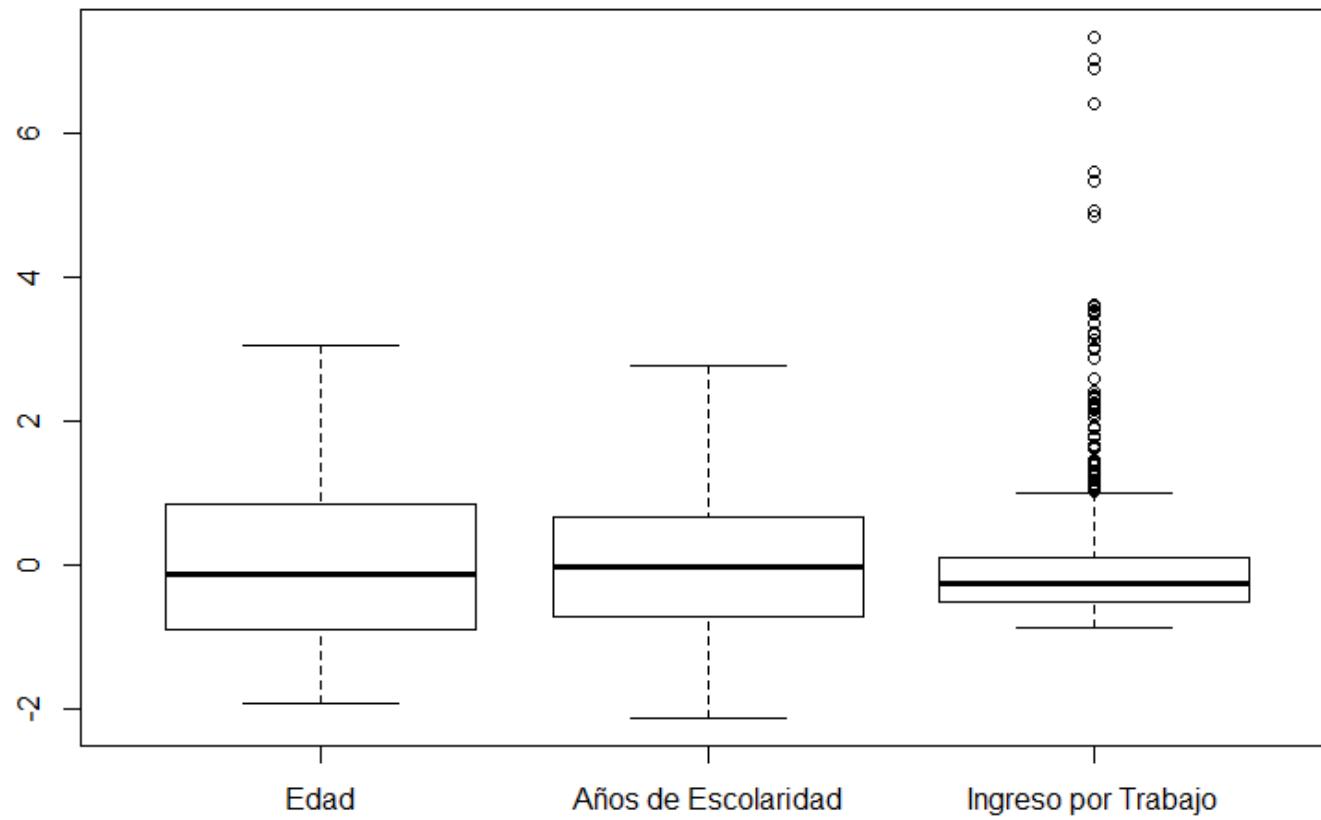
# Metodología

1. Análisis descriptivo
2. Estimación del modelo
  - Predicción (ingreso por trabajo)
3. Poda o restricciones
4. Predicción de variables
5. Interpretación

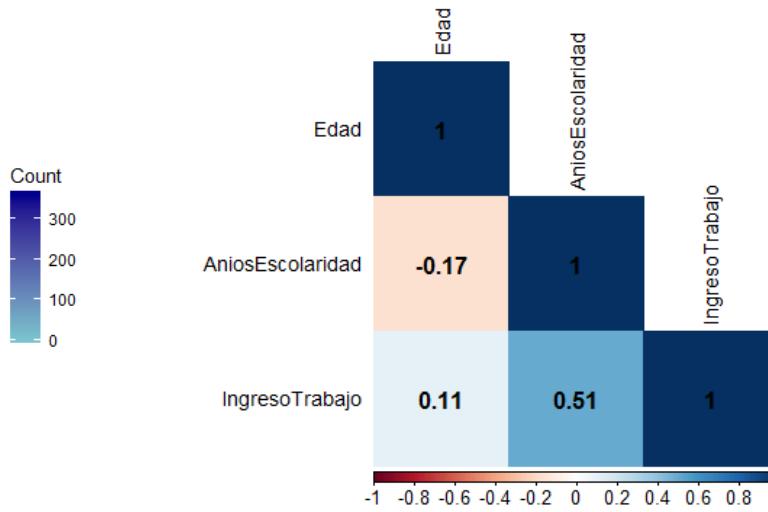
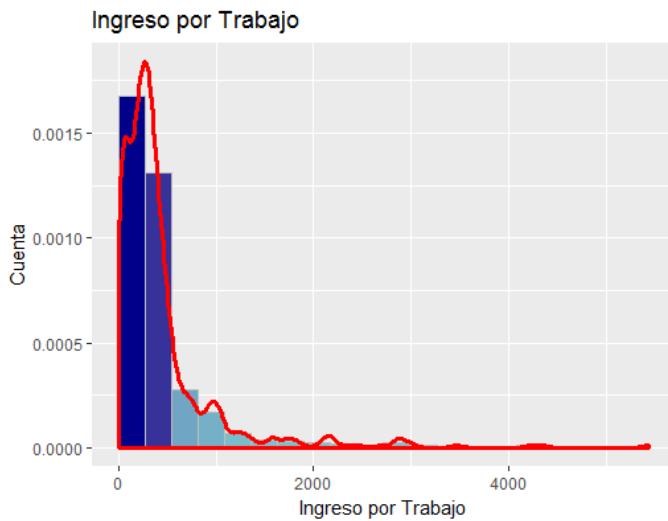
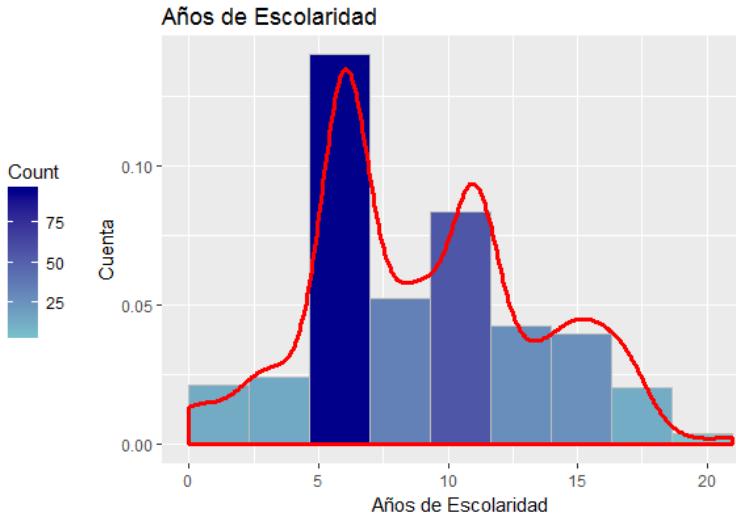
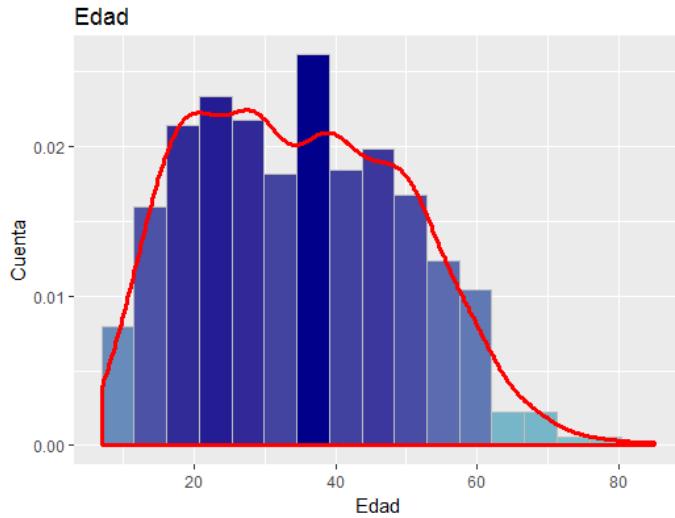
( 6 )

# Análisis descriptivos

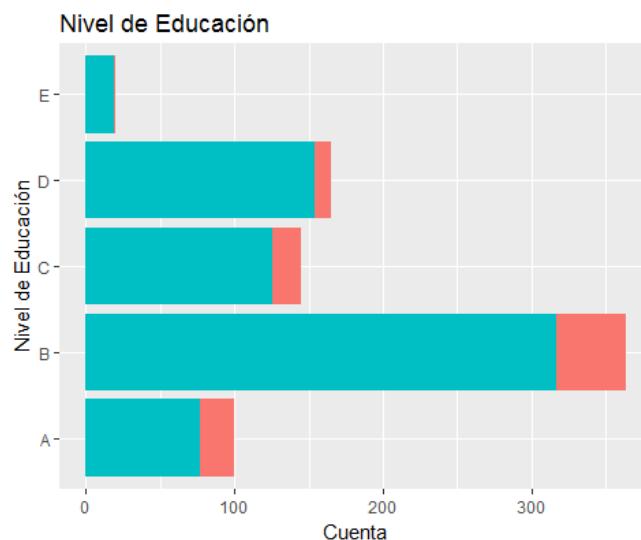
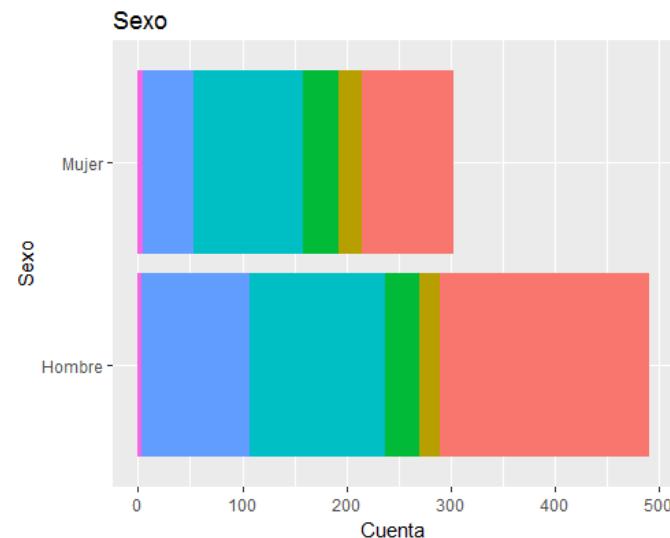
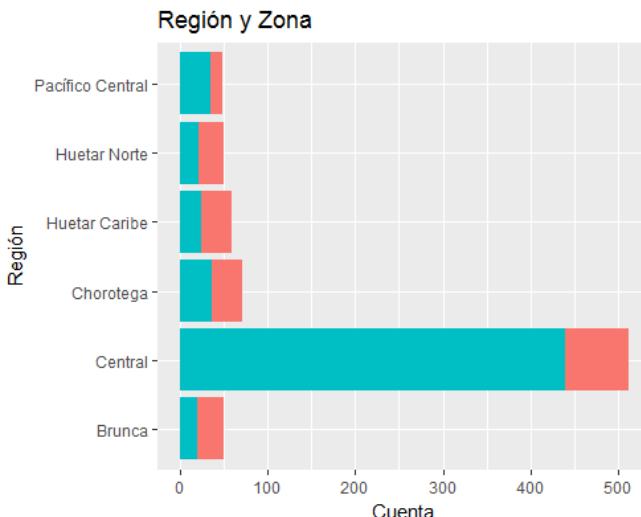
## Boxplot



# Variables continuas



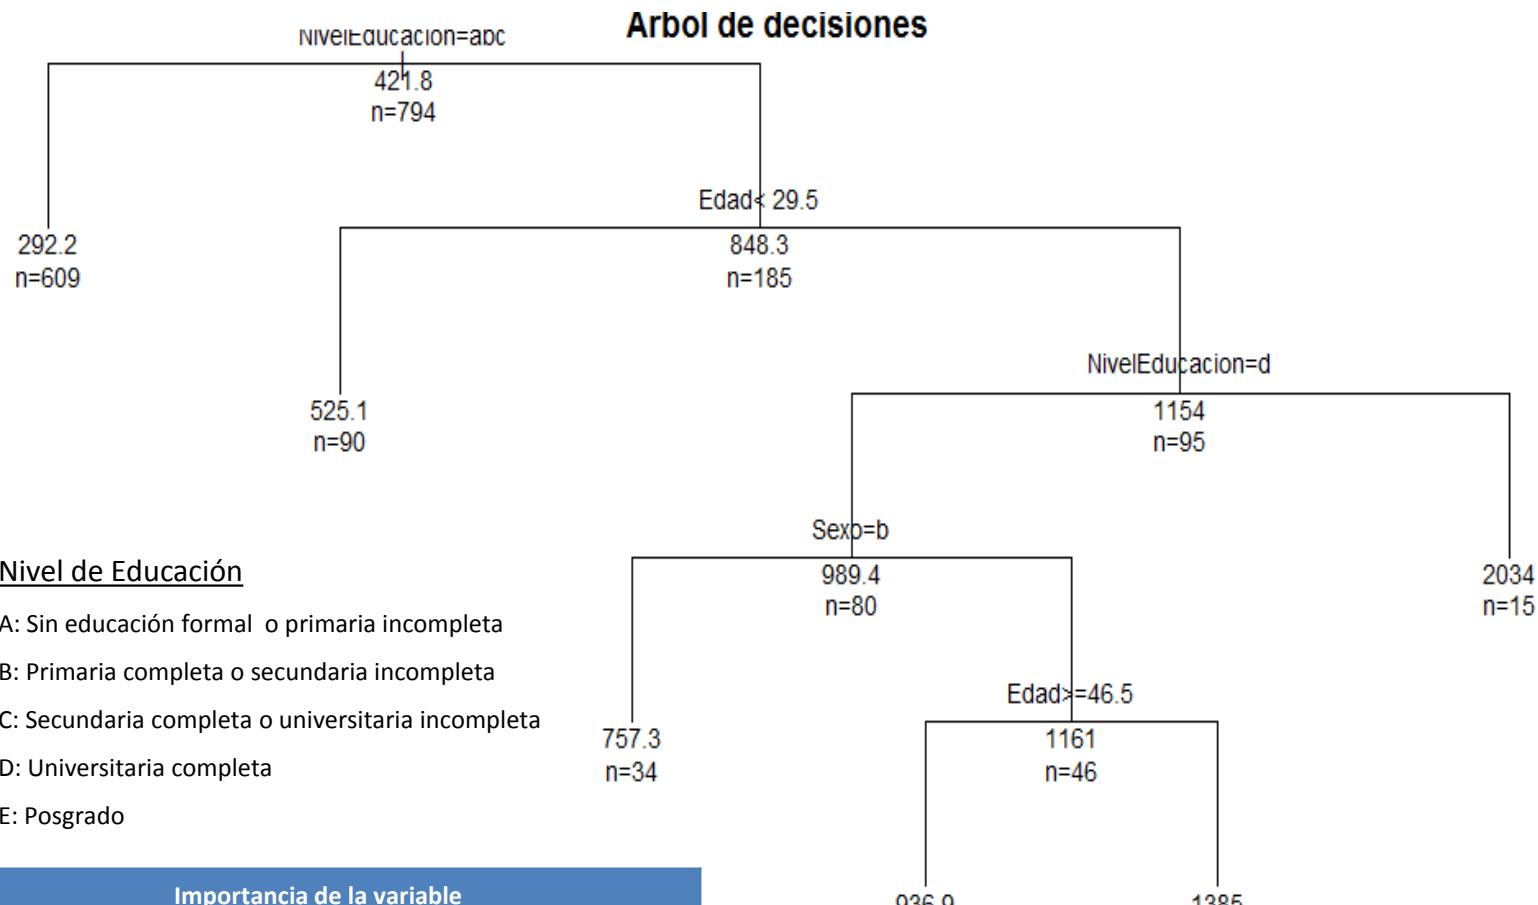
# Variables categóricas



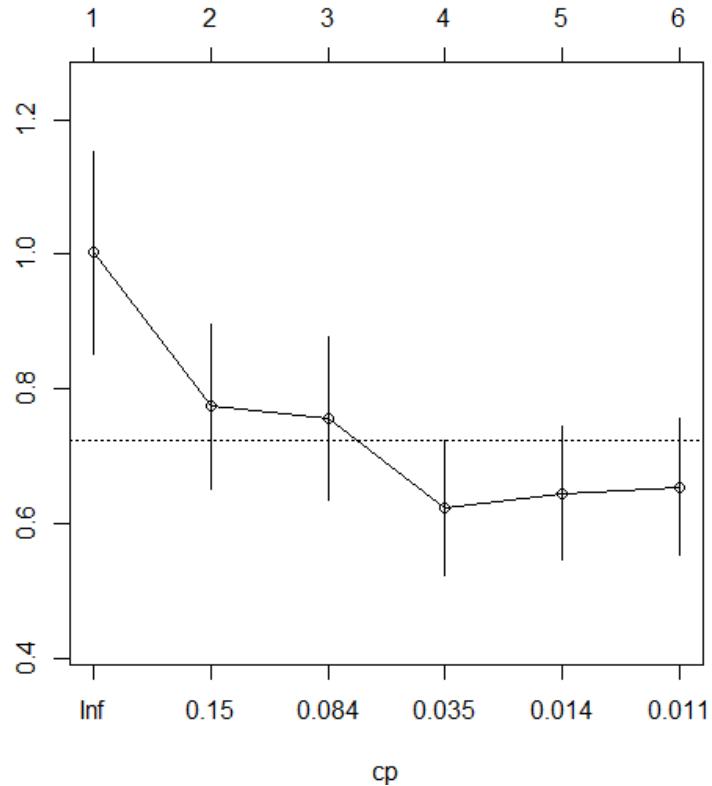
## Nivel de Educación

- A: Sin educación formal o primaria incompleta
- B: Primaria completa o secundaria incompleta
- C: Secundaria completa o universitaria incompleta
- D: Universitaria completa
- E: Posgrado

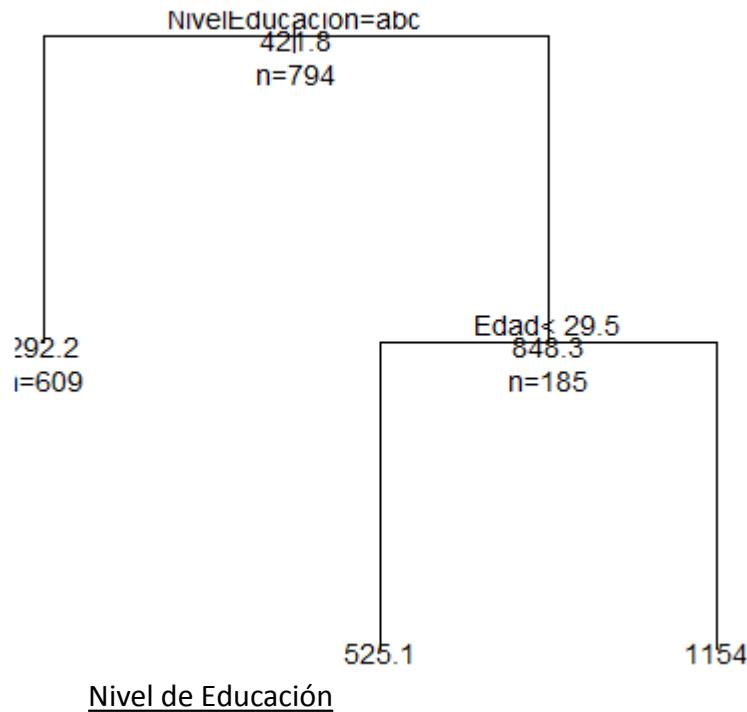
# Árbol de decisiones (CART)



# AD-CART Podado



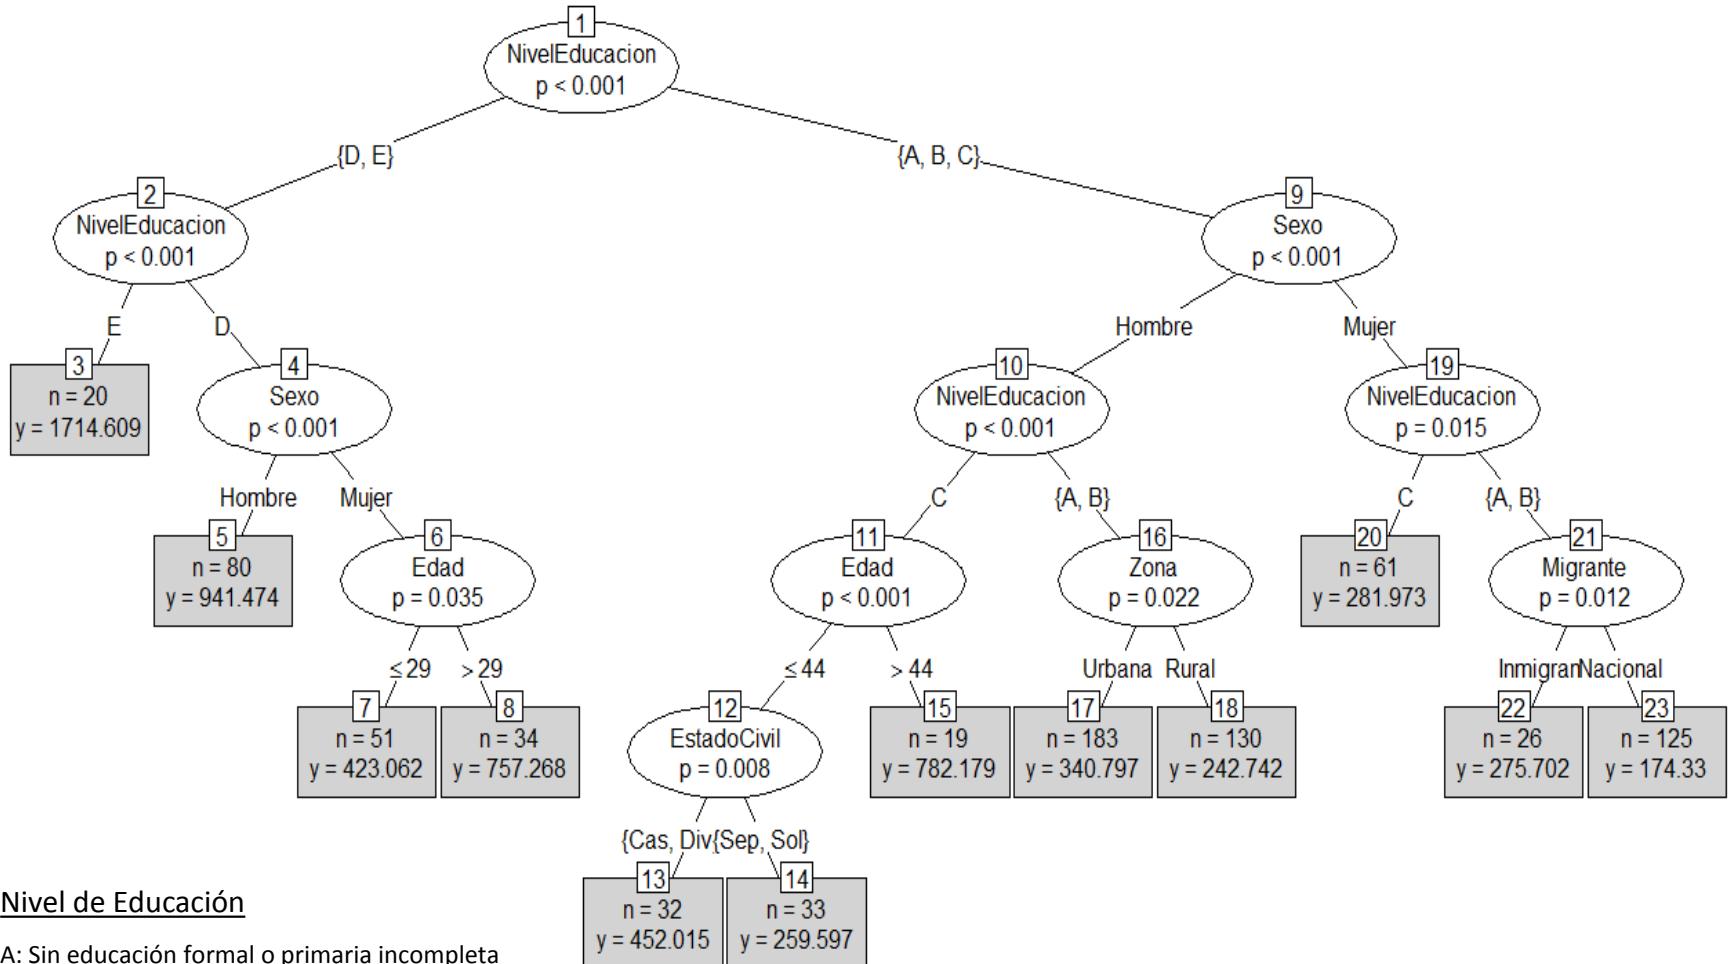
Árbol de decisiones podado



## Nivel de Educación

- A: Sin educación formal o primaria incompleta
- B: Primaria completa o secundaria incompleta
- C: Secundaria completa o universitaria incompleta
- D: Universitaria completa
- E: Posgrado

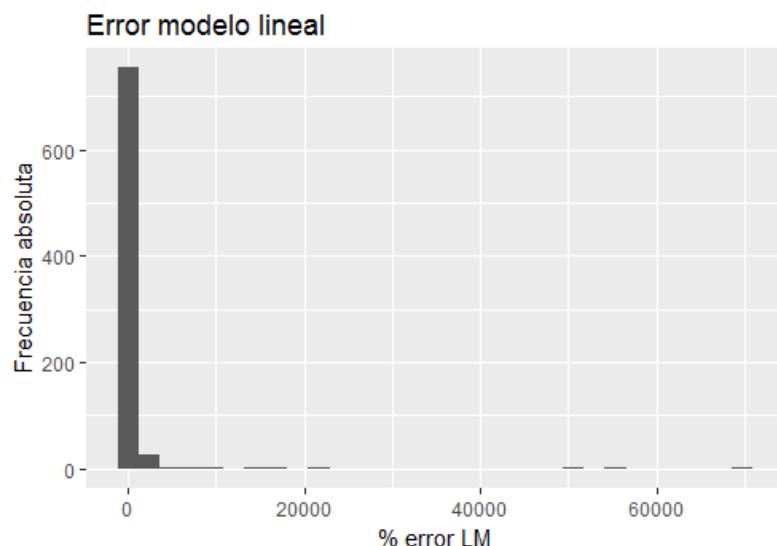
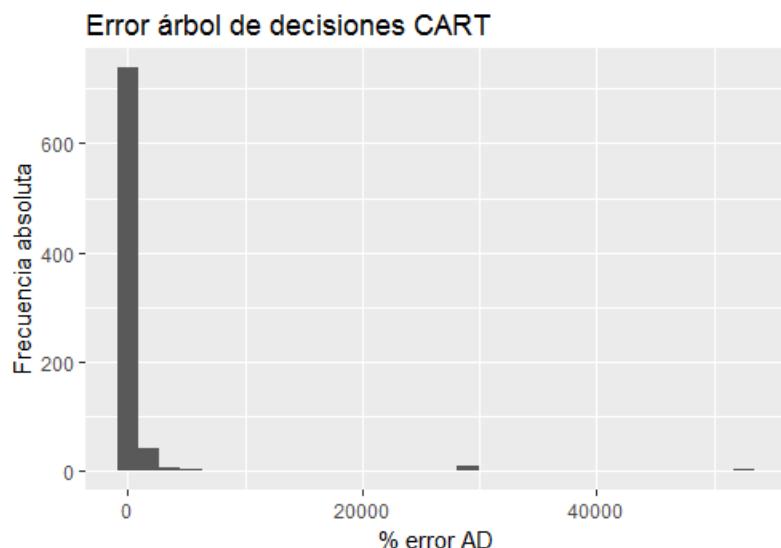
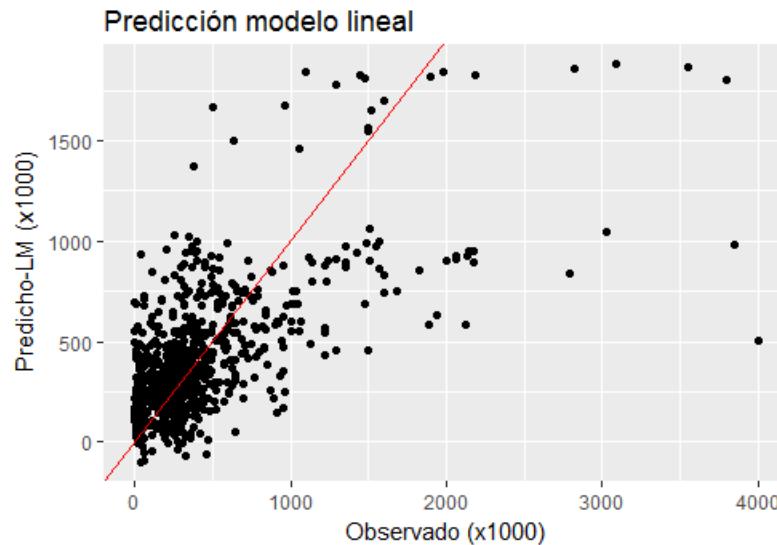
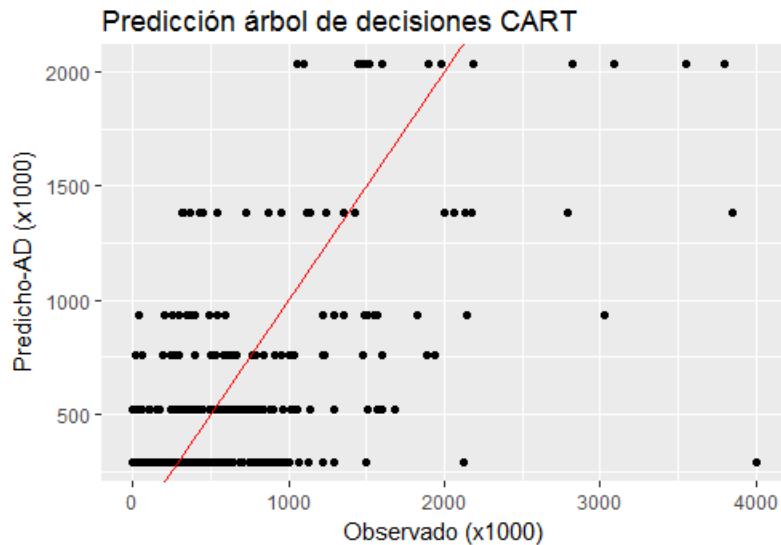
# Árbol de decisiones (inferencia condicional)



# Árbol de decisiones (AD)

<b>Id</b>	<b>Predicción AD - CART</b>	<b>Predicción modelo lineal</b>	<b>Valor real observado</b>	<b>Diferencia AD - CART</b>	<b>Diferencia ML</b>
1	292.4	292.4	692.9	-58%	-58%
1	292.4	435.3	80.0	262%	438%
3	292.4	313.2	277.1	5%	13%
4	292.4	71.4	4.0	5764%	1349%
5	292.4	64.5	294.6	-1%	-78%
⋮	⋮	⋮	⋮	⋮	⋮
<b>Promedio</b>	<b>421.8</b>	<b>306.8</b>	<b>421.8</b>	<b>577%</b>	<b>490%</b>
<b>MSE</b>	<b>213450</b>	<b>222560</b>			

# Errores por ambos métodos (%)



# Conclusiones

- Las variables de nivel de educación, edad y sexo son las principales variables explicativas.
- Otras variables relevantes son la zona, el estado civil y la condición de inmigrante.
- La variable región, no se encontró significativa con ningún método.
- Los resultados obtenidos tienen sentido, respecto a los ingresos esperados dadas ciertas condiciones.

# Conclusiones (cont.)

- Los ingresos aumentan conforme se tienen mayores niveles de educación, mayor edad y para sexo masculino.
- Los ingresos más bajos se registran para mujeres nacionales y con baja escolaridad.
- Los ingresos más altos se dan para personas con estudios de posgrado.
- Resultados de las variables son consistentes con otras investigaciones.
- No es evidente cuál método presenta los mejores resultados, sin embargo, basado en el MSE se prefieren los árboles de decisión.